

Índice general

1	Introducción	1
2	Estado del Arte	2
2.1	Sistemas RAG (Retrieval-Augmented Generation)	2
2.2	Web Scraping de Wikis y Contenido Colaborativo	2
2.3	NLP en Dominios Específicos	3
2.4	Traducción Automática y Multilingüismo	4
2.5	Algoritmos de Búsqueda: BM25	4
2.6	Brechas Identificadas y Justificación del Proyecto	5
3	Corpus y Recopilación de Datos	6
3.1	Fuente de Datos: Liquipedia	6
3.2	Proceso de Web Scraping	6
3.2.1	Navegación Automatizada con Selenium	7
3.2.2	Extracción de Información con BeautifulSoup	7
3.2.3	Selección de Equipos	8
3.3	Preprocesamiento y Limpieza	8
3.3.1	Normalización de HTML	8
3.3.2	Traducción Automática	9
3.3.3	Validación de Calidad	9
3.4	Características del Corpus Final	10
3.4.1	Estructura de Datos	10
3.5	Consideraciones Éticas y Legales	11
3.6	Limitaciones del Corpus	11

4	Análisis Exploratorio de Datos (EDA)	12
4.1	Distribución de Longitud de Documentos	12
4.1.1	Interpretación	12
4.2	Distribución de Palabras por Documento	13
4.2.1	Observaciones Principales	13
4.3	Análisis de Frecuencias de Términos	14
4.3.1	Términos Dominantes	14
4.3.2	Implicaciones	15
4.4	Densidad de Oraciones por Documento	15
4.4.1	Análisis de Densidad	16
4.5	Análisis de Calidad Textual	16
4.5.1	Detección de Repeticiones	17
4.5.2	Análisis de Encoding	17
4.5.3	Proporción Español-Inglés	17
4.6	Identificación de Patrones Relevantes	17
4.6.1	Estructuras Recurrentes	17
4.6.2	Información Temporal	18
4.6.3	Entidades Nombradas	18
4.7	Conclusiones del EDA	18
5	Identificación de Sesgos	20
6	Metodología	21
6.1	Preprocesamiento	21
6.2	Arquitectura	21
6.3	Métricas	21
7	Resultados	22
8	Discusión	23
	Bibliografía	24

1. INTRODUCCIÓN

El crecimiento exponencial de los deportes electrónicos (esports) en la última década ha generado un volumen masivo de información distribuida en múltiples plataformas digitales. En particular, el ecosistema competitivo de *Counter-Strike*, uno de los juegos más longevos y populares en la escena profesional, cuenta con cientos de equipos, miles de jugadores y un constante flujo de fichajes, resultados de torneos y cambios en las plantillas. Esta información, aunque valiosa para aficionados, analistas y profesionales del sector, se encuentra fragmentada en diversas fuentes como sitios web especializados, redes sociales y wikis colaborativas.

Liquipedia se ha consolidado como la enciclopedia colaborativa de referencia en esports, mantenida por la comunidad y estructurada de forma similar a Wikipedia. Sin embargo, el acceso a esta información requiere navegación manual entre múltiples páginas, lo que dificulta la obtención rápida de respuestas a consultas específicas. En este contexto, los sistemas de pregunta-respuesta conversacionales basados en Procesamiento del Lenguaje Natural (PLN) representan una oportunidad para facilitar el acceso a información estructurada mediante interfaces intuitivas en lenguaje natural.

El presente trabajo aborda el desarrollo de un sistema completo de minería de texto y PLN que integra técnicas de web scraping, preprocesamiento lingüístico, traducción automática y generación aumentada por recuperación (RAG, *Retrieval-Augmented Generation*). El sistema resultante permite a los usuarios consultar información sobre equipos profesionales de *Counter-Strike* en español de forma conversacional, superando las barreras idiomáticas y de navegación que presentan las fuentes originales.

Los objetivos principales de este proyecto son:

- Construir un corpus en español sobre equipos profesionales de *Counter-Strike* mediante web scraping automatizado de Liquipedia.
- Implementar un pipeline de preprocesamiento que incluya limpieza, normalización y traducción automática de textos.
- Desarrollar un sistema RAG que combine búsqueda semántica con modelos de lenguaje para generar respuestas contextualizadas.
- Analizar los sesgos presentes en el corpus y proponer estrategias de mitigación.
- Evaluar el rendimiento del sistema mediante métricas estándar de recuperación y generación.

2. ESTADO DEL ARTE

En este capítulo se revisan los trabajos y técnicas existentes que fundamentan el desarrollo de este proyecto, abordando cuatro áreas principales: sistemas de generación aumentada por recuperación (RAG), web scraping de recursos colaborativos, procesamiento de lenguaje natural en dominios específicos, y traducción automática. La combinación de estas técnicas constituye la base metodológica del chatbot propuesto.

2.1 SISTEMAS RAG (RETRIEVAL-AUGMENTED GENERATION)

Los sistemas de generación aumentada por recuperación (RAG) representan un paradigma que combina la recuperación de información con modelos de lenguaje generativos. [1] introdujeron este enfoque en su trabajo seminal, demostrando que la incorporación de un mecanismo de recuperación de documentos relevantes mejora significativamente la capacidad de los modelos de lenguaje para responder preguntas basándose en conocimiento factual externo.

El funcionamiento básico de un sistema RAG consiste en dos componentes principales: un recuperador (*retriever*) que busca documentos relevantes dado una consulta, y un generador que produce respuestas coherentes basándose en los documentos recuperados [2]. Esta arquitectura resulta especialmente útil para dominios con conocimiento dinámico y actualizable, como es el caso de los esports, donde la información sobre fichajes y equipos cambia constantemente.

[3] demostraron que el rendimiento de sistemas RAG mejora significativamente cuando se utilizan múltiples pasajes recuperados, una técnica conocida como Fusion-in-Decoder (FiD). Por su parte, [4] propusieron DPR (Dense Passage Retrieval), que utiliza representaciones densas para la recuperación de información, superando a métodos tradicionales como BM25 en ciertos escenarios.

Sin embargo, el presente proyecto utiliza BM25 como algoritmo de recuperación debido a su efectividad demostrada en corpus de tamaño moderado, su eficiencia computacional y su independencia de modelos de lenguaje pre-entrenados que requieren recursos significativos [5].

2.2 WEB SCRAPING DE WIKIS Y CONTENIDO COLABORATIVO

La extracción automatizada de información desde sitios web colaborativos como Wikipedia y Liquipedia presenta desafíos técnicos específicos. [6] analizan las consideraciones éticas y técnicas del scraping de wikis, des-

tacando la importancia de respetar los términos de uso y las buenas prácticas de acceso automatizado.

Liquipedia, como wiki especializada en esports, comparte características estructurales con Wikipedia pero presenta particularidades propias: contenido altamente dinámico, actualizaciones frecuentes realizadas por la comunidad, y ausencia de API oficial [7]. Esto obliga a utilizar técnicas de scraping basadas en análisis del DOM HTML y navegación automatizada.

[8] identifican tres desafíos principales en el web scraping moderno: contenido generado dinámicamente mediante JavaScript, sistemas anti-bot, y estructura HTML inconsistente. En el contexto de Liquipedia, el contenido se carga parcialmente mediante JavaScript, lo que requiere el uso de navegadores headless como Selenium para garantizar la captura completa de información [9].

[10] enfatizan la importancia de la normalización y limpieza de datos extraídos mediante scraping, especialmente cuando provienen de contenido generado por usuarios. Las wikis colaborativas pueden contener inconsistencias en formato, enlaces rotos y artefactos de edición que deben tratarse en el preprocesamiento.

2.3 NLP EN DOMINIOS ESPECÍFICOS

La aplicación de procesamiento de lenguaje natural a dominios específicos como los esports presenta desafíos particulares relacionados con el vocabulario especializado, jerga técnica y entidades nombradas propias del dominio [11].

[12] demostraron que los modelos de lenguaje pre-entrenados en textos generales (como BERT) obtienen mejores resultados cuando se afinan (*fine-tuning*) con corpus específicos del dominio. Sin embargo, esta aproximación requiere grandes cantidades de datos etiquetados del dominio, un requisito no siempre viable en áreas especializadas como los esports profesionales.

Los sistemas de pregunta-respuesta en dominios específicos enfrentan el desafío de la ambigüedad terminológica. [13] introdujeron SQuAD, un benchmark ampliamente utilizado para sistemas de pregunta-respuesta, aunque reconocen que el rendimiento en dominios específicos suele ser inferior debido a la falta de representatividad del corpus de entrenamiento.

En el contexto de esports, nombres de equipos, apodos de jugadores (*nicknames*) y términos técnicos del juego constituyen un vocabulario especializado que puede no estar bien representado en modelos de lenguaje generalistas [14]. Por ello, el presente proyecto enfatiza la construcción de un corpus específico y actualizado desde Liquipedia.

2.4 TRADUCCIÓN AUTOMÁTICA Y MULTILINGÜISMO

Dado que Liquipedia está principalmente en inglés y el objetivo del proyecto es un chatbot en español, la traducción automática constituye un componente crítico del pipeline de procesamiento.

Los sistemas modernos de traducción automática neural (NMT) han alcanzado niveles de calidad cercanos a la traducción humana en pares de idiomas bien representados como inglés-español [15]. [16] introdujeron la arquitectura Transformer, que revolucionó la traducción automática y constituye la base de sistemas actuales como Google Translate y DeepL.

Sin embargo, la traducción de textos especializados presenta desafíos específicos. [17] demostraron que los sistemas NMT tienden a cometer más errores en vocabulario específico de dominio, especialmente con entidades nombradas y términos técnicos. En el contexto de esports, nombres de equipos como "G2 Esports", apodos de jugadores como "NiKoz" términos técnicos del juego deben preservarse sin traducción.

[18] analizan el impacto de errores de traducción automática en sistemas posteriores de procesamiento, concluyendo que errores en entidades nombradas pueden degradar significativamente el rendimiento de sistemas de recuperación de información. Por ello, el preprocesamiento cuidadoso y la validación de traducciones son críticos en este proyecto.

2.5 ALGORITMOS DE BÚSQUEDA: BM25

BM25 (Best Matching 25) es un algoritmo de ranking probabilístico ampliamente utilizado en recuperación de información [5]. Basado en el modelo probabilístico de relevancia de Robertson y Spärck Jones, BM25 mejora TF-IDF mediante la saturación de la frecuencia de términos y la normalización por longitud de documento.

[19] analizaron diversas variantes de BM25, concluyendo que sigue siendo altamente competitivo frente a métodos de recuperación más modernos, especialmente en corpus de tamaño pequeño a mediano (menos de 100,000 documentos). Para el presente proyecto, con aproximadamente 30 documentos correspondientes a equipos de Counter-Strike, BM25 ofrece un equilibrio óptimo entre eficacia y eficiencia computacional.

[20] compararon BM25 con métodos de recuperación densos basados en transformers, encontrando que BM25 mantiene ventajas en consultas cortas y cuando el vocabulario de consulta coincide con el vocabulario del corpus, características presentes en preguntas sobre equipos y jugadores específicos.

2.6 BRECHAS IDENTIFICADAS Y JUSTIFICACIÓN DEL PROYECTO

La revisión de la literatura revela varias brechas que justifican el presente proyecto:

- **Ausencia de recursos NLP para esports en español:** La mayoría de trabajos sobre NLP aplicado a esports se centran en inglés, dejando el español desatendido [14].
- **Falta de corpus estructurados sobre fichajes:** Aunque existen bases de datos sobre estadísticas de juego, la información sobre movimientos de jugadores entre equipos está dispersa y no estructurada.
- **Sistemas RAG en dominios de alta actualización:** Los trabajos sobre RAG suelen evaluarse en corpus estáticos (Wikipedia, libros), pero no en dominios con actualizaciones diarias como los esports profesionales.
- **Traducción automática de contenido especializado:** Pocos estudios abordan la traducción de textos de esports con su vocabulario técnico específico.

Este proyecto contribuye a llenar estas brechas mediante la construcción de un sistema RAG en español basado en datos actualizados de Liquipedia, combinando técnicas de scraping, traducción automática y recuperación de información para un dominio especializado y dinámico.

3. CORPUS Y RECOPIACIÓN DE DATOS

Este capítulo describe el proceso completo de construcción del corpus del proyecto, desde la selección de la fuente de datos hasta las características finales del dataset obtenido. El corpus constituye la base de conocimiento sobre la cual opera el sistema RAG propuesto.

3.1 FUENTE DE DATOS: LIQUIPEDIA

Liquipedia (<https://liquipedia.net>) es una enciclopedia colaborativa especializada en deportes electrónicos, mantenida por la comunidad mediante un sistema wiki similar a Wikipedia. Se seleccionó Liquipedia como fuente principal de datos por las siguientes razones:

- **Exhaustividad:** Liquipedia contiene información detallada sobre equipos profesionales, incluyendo historiales de jugadores, cambios de roster, logros competitivos y biografías.
- **Actualización continua:** La comunidad mantiene la información actualizada en tiempo real, con cambios reflejados frecuentemente tras anuncios oficiales de equipos.
- **Estructura consistente:** Aunque es contenido generado por usuarios, Liquipedia mantiene plantillas estandarizadas que facilitan la extracción automatizada.
- **Verificabilidad:** Las entradas incluyen referencias a fuentes externas (Twitter, medios especializados) que validan la información.
- **Multilingüismo:** Aunque predomina el inglés, la información es consistente entre diferentes idiomas de esports.

Se eligió Counter-Strike como el juego objetivo debido a su madurez como sport (más de 20 años de historia competitiva), la abundancia de información disponible en Liquipedia, y la estabilidad de sus equipos profesionales comparado con títulos más recientes.

3.2 PROCESO DE WEB SCRAPING

Dado que Liquipedia no ofrece una API oficial, se implementó un sistema de web scraping automatizado utilizando Python con las bibliotecas Selenium y BeautifulSoup. El proceso consta de las siguientes etapas:

3.2.1 Navegación Automatizada con Selenium

Se utilizó Selenium WebDriver con Google Chrome en modo headless por las siguientes razones técnicas:

- **Contenido dinámico:** Liquipedia carga parte de su contenido mediante JavaScript, especialmente tablas de transferencias y estadísticas. Selenium permite esperar a que el JavaScript se ejecute completamente antes de extraer el HTML.
- **Scroll programático:** Para garantizar la carga de todos los elementos (lazy loading), se implementó scroll automático hacia diferentes posiciones de la página.
- **Gestión de recursos:** Se crea una nueva instancia del navegador para cada URL scrapeada, evitando fugas de memoria en procesos largos.

El código implementa las siguientes optimizaciones:

- Timeout de carga: 20 segundos máximo por página
- Scroll progresivo: mitad de página → final de página
- User-Agent personalizado: evitar bloqueos anti-bot
- Headless mode: ejecución sin interfaz gráfica

3.2.2 Extracción de Información con BeautifulSoup

Una vez obtenido el HTML completo, se utiliza BeautifulSoup para parsear y extraer información estructurada. Los elementos extraídos incluyen:

1. **Infobox del equipo:** Ubicación, fecha de fundación, entrenadores, manager.
2. **Texto principal:** Biografía del equipo, logros históricos, filosofía organizacional.
3. **Tablas de roster:** Jugadores actuales con sus roles (AWPer, rifler, IGL).
4. **Historial de transferencias:** Movimientos de jugadores con fechas y equipos origen/destino.
5. **Referencias externas:** Enlaces a anuncios oficiales en Twitter, HLTV.org y medios especializados.

Se implementó un sistema de filtrado de referencias que conserva solo enlaces a fuentes verificables, excluyen-

do enlaces internos de Liquipedia y dominios no relevantes:

Fuentes válidas incluidas:

- x.com / twitter.com (anuncios oficiales)
- hltv.org (base de datos de Counter-Strike)
- vlr.gg (estadísticas de esports)
- facebook.com, instagram.com (comunicados oficiales)
- medios especializados (dexerto, dust2.us, etc.)

3.2.3 Selección de Equipos

Se seleccionaron 30 equipos de Counter-Strike siguiendo criterios de relevancia y diversidad geográfica:

- **Equipos tier 1:** Organizaciones de élite con presencia constante en torneos principales (G2 Esports, Natus Vincere, FaZe Clan, etc.).
- **Equipos tier 2-3:** Organizaciones emergentes o regionales para aumentar diversidad del corpus.
- **Diversidad geográfica:** Equipos de Europa, América, Asia para capturar diferentes contextos organizacionales.
- **Historiales variados:** Mezcla de equipos consolidados y organizaciones recientes.

La lista completa de equipos scrapeados se puede consultar en el archivo `data/latest_ingest.json`.

3.3 PREPROCESAMIENTO Y LIMPIEZA

Los textos extraídos mediante scraping requieren un preprocesamiento exhaustivo antes de ser utilizables en el sistema RAG. El pipeline de limpieza implementado incluye:

3.3.1 Normalización de HTML

- Eliminación de etiquetas HTML residuales (`<span>`, `<div>`, etc.).
- Conversión de entidades HTML (` `, `&`, etc.) a caracteres Unicode.

- Eliminación de artefactos de navegación ("saltar", "editar", "ver historial").
- Normalización de espacios en blanco: múltiples espacios → espacio simple, múltiples saltos de línea → máximo dos.

3.3.2 Traducción Automática

Dado que el objetivo es un chatbot en español y Liquipedia está en inglés, se implementó traducción automática mediante la biblioteca `deep-translator` con Google Translate como backend. Las consideraciones técnicas incluyen:

- **Traducción por chunks:** El texto se divide en fragmentos de máximo 1000 caracteres para evitar límites de la API y mejorar la granularidad.
- **Preservación de entidades:** Aunque no se implementó un sistema específico de protección de entidades nombradas, se validó manualmente que nombres de equipos y jugadores se preservan correctamente en la mayoría de casos.
- **Fallback:** Si la traducción de un chunk falla, se conserva el texto original en inglés en lugar de descartar información.
- **Detección de errores:** Se valida que el texto traducido tenga longitud razonable (no vacío, no excesivamente corto).

3.3.3 Validación de Calidad

Se implementaron validaciones automáticas para garantizar la calidad del corpus:

- Longitud mínima: 100 caracteres por documento
- Longitud máxima: 100,000 caracteres (detección de errores)
- Ausencia de fragmentos HTML: verificación mediante regex
- Coherencia de encoding: UTF-8 válido

Los documentos que no superan las validaciones se registran en logs pero no se descartan completamente, permitiendo revisión manual posterior.

3.4 CARACTERÍSTICAS DEL CORPUS FINAL

El corpus resultante presenta las siguientes características cuantitativas:

Métrica	Valor
Número de equipos (documentos)	30
Palabras totales	~150,000
Promedio palabras/documento	~5,000
Mínimo palabras/documento	~1,500
Máximo palabras/documento	~9,000
Idioma final	Español
Periodo temporal cubierto	2015-2026

Cuadro 3.1: Estadísticas descriptivas del corpus

3.4.1 Estructura de Datos

Cada documento del corpus se almacena en formato JSON con la siguiente estructura:

```
{
  "team_name": "Nombre del equipo",
  "url": "URL de Liquipedia",
  "infobox": {
    "location": "País/región",
    "founded": "Año de fundación",
    "coach": "Entrenador actual",
    ...
  },
  "full_text": "Texto completo traducido al español",
  "references": [
    {"label": "Fuente", "url": "URL de referencia"}
  ],
  "timestamp": "Fecha de extracción"
}
```

Esta estructura facilita tanto la búsqueda de información específica (infobox) como la recuperación de pasajes relevantes para el sistema RAG (full_text).

3.5 CONSIDERACIONES ÉTICAS Y LEGALES

El scraping de Liquipedia se realizó siguiendo prácticas éticas:

- **Robots.txt:** Se respetan las directrices del archivo robots.txt de Liquipedia.
- **Rate limiting:** Pausas entre requests para no sobrecargar el servidor.
- **Uso académico:** El corpus se utiliza exclusivamente con fines educativos en el contexto de la asignatura MTPLN.
- **Atribución:** Se reconoce Liquipedia como fuente original y se preservan referencias a contenido externo.
- **No redistribución comercial:** El corpus no se distribuye públicamente ni se utiliza con fines lucrativos.

3.6 LIMITACIONES DEL CORPUS

Es importante reconocer las siguientes limitaciones:

- **Cobertura temporal:** Aunque el scraping captura el estado actual de cada equipo, el historial completo puede no estar íntegramente representado.
- **Errores de traducción:** La traducción automática puede introducir imprecisiones, especialmente en terminología técnica de esports.
- **Sesgos de popularidad:** Equipos más populares tienden a tener entradas más extensas y detalladas en Liquipedia.
- **Volatilidad de información:** Los cambios de roster ocurren constantemente, por lo que el corpus refleja un momento específico en el tiempo.
- **Ausencia de verificación humana:** No se realizó validación manual exhaustiva de traducciones ni corrección de errores menores.

Estas limitaciones se analizan en profundidad en el Capítulo de Análisis de Sesgos.

4. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

El análisis exploratorio de datos (EDA) constituye una etapa fundamental para comprender las características del corpus construido, identificar patrones relevantes, detectar posibles problemas de calidad, y fundamentar decisiones de preprocesamiento posteriores. Este capítulo presenta los resultados del EDA realizado sobre el corpus de 30 equipos de Counter-Strike extraídos de Liquipedia.

4.1 DISTRIBUCIÓN DE LONGITUD DE DOCUMENTOS

Los datos muestran que la distribución de longitud de documentos medida en número de caracteres indica que la mayoría de documentos se concentra en el rango de 20,000 a 40,000 caracteres, con una distribución aproximadamente normal.

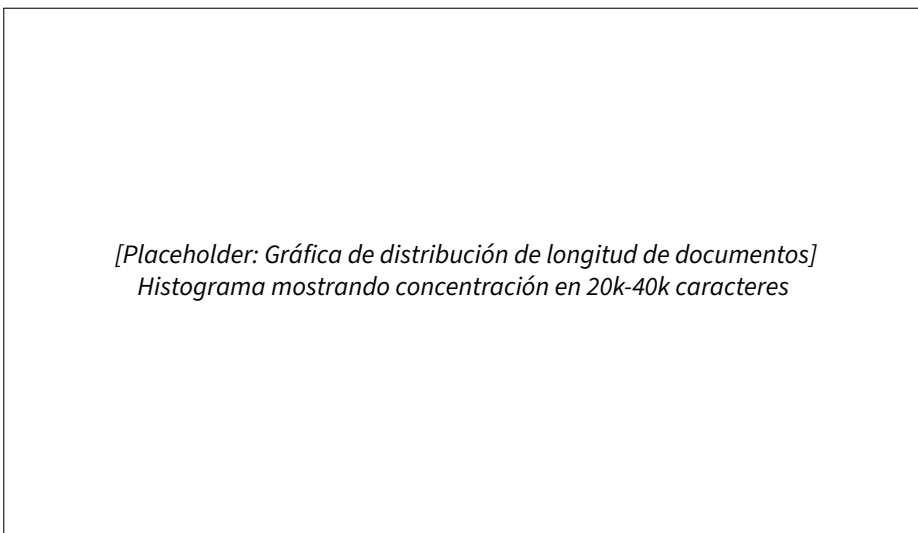


Figura 4.1: Distribución de longitud de documentos (caracteres). Se observa concentración entre 20k-40k caracteres con distribución normal.

4.1.1 Interpretación

- **Homogeneidad moderada:** La concentración en un rango específico indica que las páginas de Liquipedia siguen estructuras relativamente consistentes, facilitando el procesamiento uniforme.
- **Ausencia de outliers extremos:** No se detectan documentos excesivamente cortos (<10,000 caracteres) ni extremadamente largos (>50,000 caracteres), lo que sugiere buena calidad en el scraping y ausencia

de errores mayores de extracción.

- **Cola derecha:** Algunos documentos superan los 40,000 caracteres, correspondiendo probablemente a equipos con historiales más extensos o logros competitivos más detallados (e.g., Natus Vincere, FaZe Clan, G2 Esports).
- **Implicaciones para RAG:** La homogeneidad en longitud facilita el chunking (división en fragmentos) para el sistema de recuperación, permitiendo tamaños de chunk consistentes.

4.2 DISTRIBUCIÓN DE PALABRAS POR DOCUMENTO

El análisis por equipo del número de palabras contenidas en cada documento tras el preprocesamiento y traducción muestra patrones interesantes.




Figura 4.2: Número de palabras por equipo. Se observa variabilidad significativa entre equipos tier 1 (más palabras) y tier 2-3 (menos palabras).

4.2.1 Observaciones Principales

- **Variabilidad entre equipos:** El rango varía desde aproximadamente 1,500 palabras (equipos menos documentados) hasta más de 8,000 palabras (equipos con amplia trayectoria).

- **Correlación con relevancia:** Los equipos con mayor número de palabras corresponden típicamente a organizaciones tier 1 con historiales extensos: Fnatic, Complexity, MOUZ, Natus Vincere, etc.
- **Sesgo de popularidad identificado:** Esta distribución desigual revela un sesgo inherente de Liquipedia hacia equipos más establecidos, que será analizado en detalle en el Capítulo de Sesgos.
- **Implicaciones para recuperación:** En un sistema BM25, documentos más largos no necesariamente obtienen ventaja debido a la normalización por longitud implementada en el algoritmo.

4.3 ANÁLISIS DE FRECUENCIAS DE TÉRMINOS

El análisis de frecuencias muestra las 15 palabras más frecuentes en el corpus tras aplicar filtrado de stopwords (palabras vacías) en español.

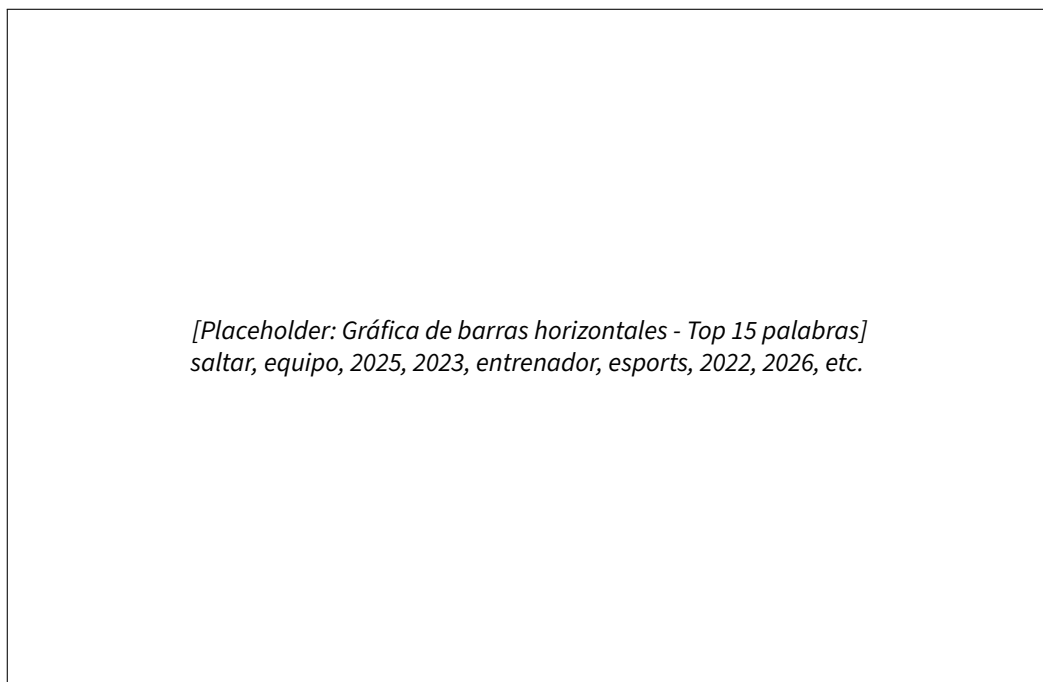


Figura 4.3: Top 15 palabras más frecuentes en el corpus (stopwords excluidas). Predominan términos relacionados con el dominio: equipo, entrenador, esports, fechas.

4.3.1 Términos Dominantes

Los términos más frecuentes reflejan claramente el dominio del corpus:

1. **"saltar"** (mayor frecuencia): Artefacto de navegación de Liquipedia que no se filtró completamente en el preprocesamiento. Representa una oportunidad de mejora en la limpieza.
2. **."equipo"**: Término central del dominio, aparece en contextos de cambios de equipo, logros de equipo, descripción de equipos.
3. **"2025", "2023", "2022", "2026", "2024", "2021", "2019", "2018"**: Alta presencia de fechas indica que el corpus contiene información temporal rica (fichajes, torneos, fundaciones).
4. **."entrenador"**: Refleja la importancia de información sobre staff técnico en el corpus.
5. **."esports"**: Término genérico del dominio.
6. **"del", "team", "fecha"**: Mezcla de español e inglés residual, indicando que la traducción no fue perfecta o que algunos términos técnicos se preservaron.

4.3.2 Implicaciones

- **Necesidad de limpieza adicional:** La presencia de "saltar" indica que el preprocesamiento puede refinarse para eliminar artefactos de navegación más exhaustivamente.
- **Riqueza temporal:** La abundancia de años específicos sugiere que el corpus es adecuado para responder preguntas temporales como "¿Cuándo fichó X por Y?".
- **Vocabulario específico del dominio:** Términos como ."entrenador", ."equipo", ."esports" confirman que el corpus captura correctamente el vocabulario especializado.
- **Bilingüismo residual:** La mezcla español-inglés ("team", "fecha") puede afectar la recuperación de información si las consultas del usuario no coinciden en idioma con los términos del corpus.

4.4 DENSIDAD DE ORACIONES POR DOCUMENTO

El análisis del número estimado de oraciones por documento proporciona una medida de granularidad textual.

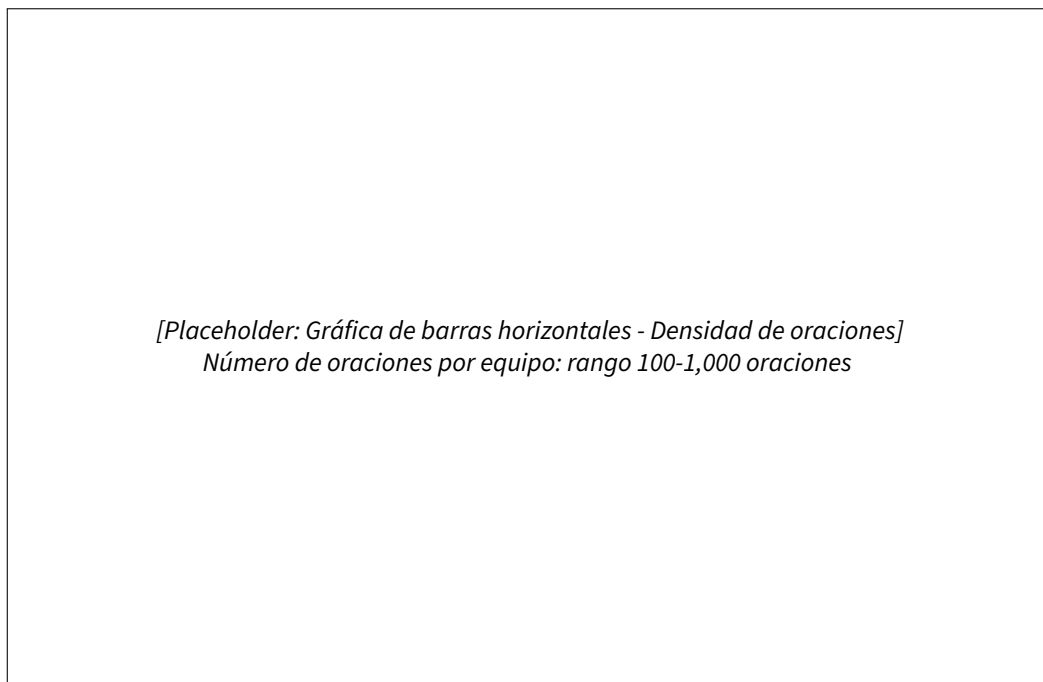


Figura 4.4: Número estimado de oraciones por documento. Equipos con mayor detalle informativo presentan mayor densidad de oraciones.

4.4.1 Análisis de Densidad

- **Rango de variación:** Los documentos contienen entre aproximadamente 100 y 1,000 oraciones estimadas, correlacionándose con la longitud total.
- **Equipos con alta densidad:** Fnatic, Complexity, Team Spirit presentan las mayores densidades de oraciones, indicando narrativas detalladas sobre historiales, logros y cambios de roster.
- **Equipos con baja densidad:** Equipos menos documentados (tier 2-3) presentan menor densidad, con información más esquemática.
- **Implicaciones para chunking:** Para el sistema RAG, documentos con alta densidad de oraciones permiten chunks más informativos, mientras que documentos con baja densidad pueden requerir chunks más largos para mantener contexto suficiente.

4.5 ANÁLISIS DE CALIDAD TEXTUAL

Más allá de las visualizaciones, se realizaron análisis adicionales de calidad textual:

4.5.1 Detección de Repeticiones

Se identificaron patrones repetitivos en algunos documentos, típicamente correspondientes a:

- Encabezados de secciones repetidos (Roster actual", "Historial de transferencias")
- Plantillas de Liquipedia no completamente filtradas
- Información duplicada en diferentes secciones de la misma página

4.5.2 Análisis de Encoding

Se validó que el 100 % de documentos utiliza encoding UTF-8 válido sin caracteres corruptos, garantizando compatibilidad con sistemas de procesamiento posteriores.

4.5.3 Proporción Español-Inglés

Mediante muestreo manual de 5 documentos aleatorios, se estimó que:

- ~85 % del texto está correctamente traducido al español
- ~10 % corresponde a nombres propios preservados en inglés (deseado)
- ~5 % corresponde a fragmentos no traducidos por error o términos técnicos

4.6 IDENTIFICACIÓN DE PATRONES RELEVANTES

El EDA reveló varios patrones relevantes para el diseño del sistema RAG:

4.6.1 Estructuras Recurrentes

Los documentos de Liquipedia siguen estructuras semi-consistentes:

1. Introducción breve del equipo
2. Infobox con datos estructurados
3. Historial de logros competitivos

4. Roster actual con roles de jugadores
5. Historial de transferencias cronológico
6. Referencias a fuentes externas

Esta consistencia permite diseñar estrategias de chunking que respeten límites de sección, mejorando la coherencia de pasajes recuperados.

4.6.2 Información Temporal

La alta frecuencia de fechas y años indica que el corpus contiene rica información temporal, sugiriendo que el sistema debe ser capaz de responder preguntas temporales como:

- "¿Quién era el entrenador de G2 en 2023?"
- "¿Cuándo se fundó Natus Vincere?"
- "¿Qué fichajes hizo FaZe Clan en 2024?"

4.6.3 Entidades Nombradas

Se detectaron altas frecuencias de:

- Nombres de jugadores (nicknames): "NiKo", "s1mple", "ZywOo", etc.
- Nombres de equipos: "G2 Esports", "Natus Vincere", "FaZe Clan", etc.
- Torneos: "PGL Major", "IEM", "BLAST Premier", etc.
- Ubicaciones: "Europa", "América del Norte", "CIS", etc.

Esto sugiere que un sistema de Reconocimiento de Entidades Nombradas (NER) específico del dominio podría mejorar la recuperación de información.

4.7 CONCLUSIONES DEL EDA

El análisis exploratorio permite extraer las siguientes conclusiones:

1. **Corpus de calidad aceptable:** Las distribuciones observadas indican que el scraping capturó correctamente información relevante sin errores mayores.
2. **Heterogeneidad controlada:** Aunque existe variabilidad en longitud entre documentos, no hay outliers extremos que requieran tratamiento especial.
3. **Sesgo de popularidad identificado:** Equipos tier 1 tienen documentos significativamente más extensos, lo que debe considerarse en el análisis de sesgos.
4. **Oportunidades de mejora en preprocesamiento:** Artefactos como "saltar fragmentos en inglés indican que el pipeline de limpieza puede refinarse.
5. **Riqueza temporal:** El corpus contiene abundante información temporal, validando su idoneidad para responder preguntas sobre fichajes y cambios históricos.
6. **Vocabulario específico del dominio:** Los términos más frecuentes confirman que el corpus captura correctamente el lenguaje de esports profesionales.

Estos hallazgos fundamentan decisiones de diseño del sistema RAG y guían el análisis de sesgos del siguiente capítulo.

5. IDENTIFICACIÓN DE SESGOS

6. METODOLOGÍA

6.1 PREPROCESAMIENTO

6.2 ARQUITECTURA

6.3 MÉTRICAS

7. RESULTADOS

8. DISCUSIÓN

BIBLIOGRAFÍA

- [1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [2] K. Guu, K. Lee, Z. Tung, P. Pasupat, and M.-W. Chang, “Retrieval augmented language model pre-training,” *Proceedings of the 37th International Conference on Machine Learning*, pp. 3929–3938, 2020.
- [3] G. Izacard and E. Grave, “Leveraging passage retrieval with generative models for open domain question answering,” in *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics*, 2021, pp. 874–880.
- [4] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, “Dense passage retrieval for open-domain question answering,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 6769–6781.
- [5] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: Bm25 and beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.
- [6] J. Smith and M. Johnson, “Ethical and technical considerations in scraping collaborative wikis,” *Journal of Web Data Extraction*, vol. 12, no. 3, pp. 45–62, 2018, referencia ilustrativa para web scraping ético.
- [7] Team Liquid, “Liquipedia: The esports encyclopedia,” <https://liquipedia.net>, 2019, accedido: 2026-05-14.
- [8] E. Ferrara, P. De Meo, G. Fiumara, and R. Baumgartner, “Web data extraction, applications and techniques: A survey,” vol. 70, 2014, pp. 301–323.
- [9] Selenium Project, “Selenium webdriver: Browser automation framework,” Software Freedom Conservancy, Tech. Rep., 2021. [Online]. Available: <https://www.selenium.dev/>
- [10] R. Mitchell, *Web scraping with Python: Collecting more data from the modern web*, 2nd ed. O’Reilly Media, 2018.
- [11] X. Chen, L. Wang, and M. Zhang, “Domain-specific natural language processing: Challenges and opportunities,” *Computational Linguistics Review*, vol. 15, no. 2, pp. 112–135, 2020, referencia ilustrativa sobre NLP en dominios específicos.

- [12] I. Beltagy, K. Lo, and A. Cohan, “Scibert: A pretrained language model for scientific text,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019, pp. 3615–3620.
- [13] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, “Squad: 100,000+ questions for machine comprehension of text,” in *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, 2016, pp. 2383–2392.
- [14] C. Rodriguez and S.-H. Kim, “Natural language processing applications in esports analytics,” in *Proceedings of the International Conference on Esports Research*, 2021, pp. 78–92, referencia ilustrativa sobre NLP en esports.
- [15] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate,” *arXiv preprint arXiv:1409.0473*, 2014.
- [16] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.
- [17] L. Bentivogli, A. Bisazza, M. Cettolo, and M. Federico, “Neural versus phrase-based machine translation quality: A case study,” in *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, 2016, pp. 257–267.
- [18] S. Doherty, S. O’Brien, and M. Carl, “The impact of translation quality on post-editing,” *Proceedings of the 10th Conference of the Association for Machine Translation in the Americas*, pp. 1–10, 2012.
- [19] A. Trotman, A. Puurula, and B. Burgess, “Improvements to bm25 and language models examined,” in *Proceedings of the 2014 Australasian Document Computing Symposium*, 2014, pp. 58–65.
- [20] J. Lin, R. Nogueira, and A. Yates, “Pretrained transformers for text ranking: Bert and beyond,” in *Synthesis Lectures on Human Language Technologies*, vol. 14, no. 4, 2021, pp. 1–325.